

苏州大学实验报告

院系	计算机学院	年级专业	21 计科	姓名	方浩楠	学号	2127405048
课程名称	大数据管理					成绩	
指导教师	王晶晶	同组实验者	无	实验日期	2024. 5. 16		


实 验 名 称 _____ 实 验 _____

- 一. 实验目的
- 实验通过使用 weka 对数据进行 k-means 聚类，并对最后的结果进行分析
- 二. 实验内容
- 实验通过使用 weka 对数据进行 k-means 聚类，并对最后的结果进行分析，实验的步骤如下：
1. 处理数据集
 2. 使用 weka 进行聚类
 3. 分析实验结果
- 三. 实验步骤和结果
- 数据集处理:
- 对 Wine Data Set 的 wine.data 进行处理:
1. 将 wine.data 的文件名后缀改为: *.csv。
 2. 用 office Excel 打开 wine.csv，可以得到数据总共有 14 列，既有 14 个属性。
 3. 打开 wine.names，通过内容可以知道，其 14 个属性分别为：
 - 1) Class
 - 2) Alcohol
 - 3) Malic acid
 - 4) Ash
 - 5) Alcalinity of ash
 - 6) Magnesium
 - 7) Total phenols
 - 8) Flavanoids
 - 9) Nonflavanoid phenols
 - 10) Proanthocyanins
 - 11) Color intensity
 - 12) Hue
 - 13) OD280/OD315 of diluted wines
 - 14) Proline


4. 在 wine.csv 的第一行插入空白行，将上边的属性依次填入其中，如图 21 所示：


	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U
1	Class	Alcohol	Malic acid	Ash	Alkalinity of Magnesium	Total pheno Flavonoids	Nonflavono	Proanthooy	Color intens Hue	OD280/OD3	Proline										
2	1	14.23	1.71	2.43	15.6	127	2.8	3.06	0.28	2.29	5.64	1.04	3.92	1065							
3	1	13.2	1.78	2.14	11.2	100	2.65	2.76	0.26	1.28	4.38	1.05	3.4	1050							
4	1	13.16	2.36	2.67	18.6	101	2.8	3.24	0.3	2.81	5.68	1.03	3.17	1185							
5	1	14.37	1.95	2.5	16.8	113	3.85	3.49	0.24	2.18	7.8	0.85	3.45	1480							
6	1	13.24	2.59	2.87	21	118	2.8	2.69	0.39	1.82	4.32	1.04	2.93	735							
7	1	14.2	1.76	2.45	15.2	112	3.27	3.39	0.34	1.97	6.75	1.05	2.85	1450							
8	1	14.39	1.87	2.45	14.6	96	2.5	2.52	0.3	1.98	5.25	1.02	3.58	1290							
9	1	14.06	2.15	2.61	17.6	121	2.6	2.51	0.31	1.25	5.05	1.06	3.58	1295							
10	1	14.63	1.64	2.17	14	97	2.8	2.96	0.29	1.98	5.2	1.08	2.85	1045							
11	1	13.86	1.35	2.27	16	98	2.98	3.15	0.22	1.85	7.22	1.01	3.55	1045							
12	1	14.1	2.16	2.3	18	105	2.95	3.32	0.22	2.38	5.75	1.25	3.17	1510							
13	1	14.12	1.48	2.32	16.8	95	2.2	2.43	0.26	1.57	5	1.17	2.82	1280							
14	1	13.75	1.73	2.41	16	89	2.6	2.76	0.29	1.81	5.6	1.15	2.9	1320							
15	1	14.75	1.73	2.39	11.4	91	3.1	3.69	0.43	2.81	5.4	1.25	2.73	1150							
16	1	14.38	1.87	2.38	12	102	3.3	3.64	0.29	2.96	7.5	1.2	3	1547							
17	1	13.63	1.81	2.7	17.2	112	2.85	2.91	0.3	1.46	7.3	1.28	2.88	1310							
18	1	14.3	1.92	2.72	20	120	2.8	3.14	0.33	1.97	6.2	1.07	2.65	1280							
19	1	13.83	1.57	2.62	20	115	2.95	3.4	0.4	1.72	6.6	1.13	2.57	1130							
20	1	14.19	1.59	2.48	16.5	108	3.3	3.93	0.32	1.86	8.7	1.23	2.82	1680							
21	1	13.64	3.1	2.56	15.2	116	2.7	3.03	0.17	1.66	5.1	0.96	3.36	845							
22	1	14.06	1.63	2.28	16	126	3	3.17	0.24	2.1	5.65	1.09	3.71	780							
23	1	12.93	3.8	2.65	18.6	102	2.41	2.41	0.25	1.98	4.5	1.03	3.52	770							
24	1	13.71	1.86	2.36	16.6	101	2.61	2.88	0.27	1.69	3.8	1.11	4	1035							
25	1	12.85	1.6	2.52	17.8	95	2.48	2.37	0.26	1.46	3.93	1.09	3.63	1015							
26	1	13.5	1.81	2.61	20	96	2.53	2.61	0.28	1.66	3.52	1.12	3.82	845							
27	1	13.05	2.05	3.22	25	124	2.63	2.68	0.47	1.92	3.58	1.13	3.2	830							
28	1	13.39	1.77	2.62	16.1	93	2.85	2.94	0.34	1.45	4.8	0.92	3.22	1195							
29	1	13.3	1.72	2.14	17	94	2.4	2.19	0.27	1.35	3.95	1.02	2.77	1285							
30	1	13.87	1.9	2.8	19.4	107	2.95	2.97	0.37	1.76	4.5	1.25	3.4	915							
31	1	14.02	1.68	2.21	16	96	2.65	2.33	0.26	1.98	4.7	1.04	3.59	1035							
32	1	13.73	1.5	2.7	22.5	101	3	3.25	0.29	2.38	5.7	1.19	2.71	1285							
33	1	13.58	1.66	2.36	19.1	106	2.86	3.19	0.22	1.95	6.9	1.09	2.88	1515							
34	1	13.68	1.83	2.36	17.2	104	2.42	2.69	0.42	1.97	3.84	1.23	2.87	990							
35	1	13.76	1.53	2.7	19.5	132	2.95	2.74	0.5	1.35	5.4	1.25	3	1235							
36	1	13.51	1.8	2.65	19	110	2.35	2.53	0.29	1.54	4.2	1.1	2.87	1095							
37	1	13.48	1.81	2.41	20.5	100	2.7	2.98	0.26	1.86	5.1	1.04	3.47	920							

5. 打开 weka 软件，选择 “Tool” → “ArffViewer”：




6. 在弹出的界面框内，选择“File”→“Open”弹出如下图的打开窗口，在 文件类型一栏选择 CSV data files (*.csv) 项，如图 2-3 所示；然后找到 wine.csv 文件后单击打开：





7. 接下来选择“File”→“Save as”后弹出如图 2-4 所示，选择 wine.csv 一样的路径，文件类型为 Arff data file(*.arff)，点击保存：



对 Car Evaluation Data Set 的 car.data 进行处理： 处理步骤与上示的 Wine Data Set 中 wine.data 处理方法一致，共有 7 个 属性，其 7 个属性分别为：

- 1) buying
- 2) maint
- 3) doors
- 4) persons
- 5) lug_boot
- 6) safety
- 7) class

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U
1	buying	maint	doors	persons	lug_boot	safety	class														
2	vhigh	vhigh		2	small	low	unacc														
3	vhigh	vhigh		2	small	med	unacc														
4	vhigh	vhigh		2	small	high	unacc														
5	vhigh	vhigh		2	med	low	unacc														
6	vhigh	vhigh		2	med	med	unacc														
7	vhigh	vhigh		2	med	high	unacc														
8	vhigh	vhigh		2	big	low	unacc														
9	vhigh	vhigh		2	big	med	unacc														
10	vhigh	vhigh		2	big	high	unacc														
11	vhigh	vhigh		2	4 small	low	unacc														
12	vhigh	vhigh		2	4 small	med	unacc														
13	vhigh	vhigh		2	4 small	high	unacc														
14	vhigh	vhigh		2	4 med	low	unacc														
15	vhigh	vhigh		2	4 med	med	unacc														
16	vhigh	vhigh		2	4 med	high	unacc														
17	vhigh	vhigh		2	4 big	low	unacc														
18	vhigh	vhigh		2	4 big	med	unacc														
19	vhigh	vhigh		2	4 big	high	unacc														
20	vhigh	vhigh		2 more	small	low	unacc														
21	vhigh	vhigh		2 more	small	med	unacc														
22	vhigh	vhigh		2 more	small	high	unacc														
23	vhigh	vhigh		2 more	med	low	unacc														
24	vhigh	vhigh		2 more	med	med	unacc														
25	vhigh	vhigh		2 more	med	high	unacc														
26	vhigh	vhigh		2 more	big	low	unacc														
27	vhigh	vhigh		2 more	big	med	unacc														
28	vhigh	vhigh		2 more	big	high	unacc														
29	vhigh	vhigh		3	2 small	low	unacc														
30	vhigh	vhigh		3	2 small	med	unacc														
31	vhigh	vhigh		3	2 small	high	unacc														
32	vhigh	vhigh		3	2 med	low	unacc														
33	vhigh	vhigh		3	2 med	med	unacc														
34	vhigh	vhigh		3	2 med	high	unacc														
35	vhigh	vhigh		3	2 big	low	unacc														
36	vhigh	vhigh		3	2 big	med	unacc														
37	vhigh	vhigh		3	2 big	high	unacc														

生成的 car.arff:

```

@relation car
@attribute buying {vhigh,high,med,low}
@attribute maint {vhigh,high,med,low}
@attribute doors {2,0,2,0,4,0,5more}
@attribute persons {2,0,4,0,more}
@attribute lug_boot {small,med,big}
@attribute safety {low,med,high}
@attribute Class {unacc,acc,vgood,good}


@data
vhigh,vhigh,2,0,2,0,small,low,unacc
vhigh,vhigh,2,0,2,0,small,med,unacc
vhigh,vhigh,2,0,2,0,small,high,unacc
vhigh,vhigh,2,0,2,0,med,low,unacc
vhigh,vhigh,2,0,2,0,med,med,unacc
vhigh,vhigh,2,0,2,0,med,high,unacc
vhigh,vhigh,2,0,2,0,big,low,unacc
vhigh,vhigh,2,0,2,0,big,med,unacc
vhigh,vhigh,2,0,2,0,big,high,unacc
vhigh,vhigh,2,0,4,0,small,low,unacc
vhigh,vhigh,2,0,4,0,small,med,unacc
vhigh,vhigh,2,0,4,0,small,high,unacc
vhigh,vhigh,2,0,4,0,med,low,unacc
vhigh,vhigh,2,0,4,0,med,med,unacc
vhigh,vhigh,2,0,4,0,med,high,unacc
vhigh,vhigh,2,0,4,0,big,low,unacc
vhigh,vhigh,2,0,4,0,big,med,unacc
vhigh,vhigh,2,0,4,0,big,high,unacc
vhigh,vhigh,2,0,more,small,low,unacc
vhigh,vhigh,2,0,more,small,med,unacc
vhigh,vhigh,2,0,more,small,high,unacc
vhigh,vhigh,2,0,more,med,low,unacc
vhigh,vhigh,2,0,more,med,med,unacc
vhigh,vhigh,2,0,more,med,high,unacc
vhigh,vhigh,2,0,more,big,low,unacc
vhigh,vhigh,2,0,more,big,med,unacc
vhigh,vhigh,2,0,more,big,high,unacc
vhigh,vhigh,3,0,2,0,small,low,unacc
vhigh,vhigh,3,0,2,0,small,med,unacc
vhigh,vhigh,3,0,2,0,small,high,unacc
vhigh,vhigh,3,0,2,0,med,low,unacc
vhigh,vhigh,3,0,2,0,med,med,unacc
vhigh,vhigh,3,0,2,0,med,high,unacc
vhigh,vhigh,3,0,2,0,big,low,unacc
vhigh,vhigh,3,0,2,0,big,med,unacc

```


4. SimpleKMeans 实验步骤

对 Wine Data Set 进行 SimpleKMeans 聚类:


1. 打开 weka 软件，进入“Explorer”界面中的“Preprocess”标签，单击 Open file 后弹出如下图的数据集选择窗口，选择 wine.arff 数据集文件后打开。



2. 点击进入“Cluster”：标签，单击左上角“choose”按钮，选择“SimpleKMeans” 算法：



3. 点击“choose”按钮右边显示有“SimpleKMeans...”的框格，将弹出框内“numClusters”栏内的数字改为 3，点击“OK”



weka.gui.GenericObjectEditor

weka.clusterers.SimpleKMeans

About

Cluster data using the k means algorithm. More Capabilities

canopyMaxNumCanopiesToHoldInMemory 100

canopyMinimumCanopyDensity 2.0

canopyPeriodicPruningRate 10000

canopyT1 -1.25

canopyT2 -1.0

debug False

displayStdDevs False

distanceFunction Choose **EuclideanDistance**

doNotCheckCapabilities False

dontReplaceMissingValues False

fastDistanceCalc False

initializationMethod Random

maxIterations 500

numClusters 3

numExecutionSlots 1


preserveInstancesOrder False

reduceNumberOfDistanceCalcsViaCanopies False


seed 10

Open... Save... OK Cancel



4.点击“Ignore attributes”选中“Class”一栏，并点击“Select”确认，默认 在聚类时排除该选项。




5.保持其他选项不变，点击“Start”按钮，开始数据处理，得到数据结果会显示在“Clusterer output”中，



6. 在实验界面"Result list"列出的结果上右击，点"Visualize cluster assignments"。弹出的窗口给出了各实例的散点图。




7. 点击“Save”把聚类结果保存成 arff 文件，命名为：wine result.arff。
保存的 wine_result.arff:




对 Car Evaluation Data Set 进行 SimpleKMeans 聚类:

实验步骤与本次 SimpleKMeans 算法的 Wine Data Set 的实验步骤相同，打 开的文件为 car.arff，第三
步中“numClusters”栏内的数字改为 4，其余步骤完 全相同。


打开 car.arff:




打开 car.arff 后:



修改 numClusters:




修改 ignore attributes:



然后运行

此项无法在 simpleKMeans 时运行



可能是因为对于混合型数据集（Car Evaluation Data Set），由于标称数据的存在，聚类结果可能偏离实际分类。

四. 实验总结

通过本次实验，可以看出 SimpleKMeans 算法在处理纯数值数据时表现较好，而在处理含有标称数据的混合型数据集时，效果相对较差。这一结果验证了该算法在不同类型数据集上的适用性和局限性。