

聚类实验指南

1. 实验准备

- a. 工具: weka
- b. 数据集: Wine Data Set (关于葡萄酒各类属性的数据, 纯数值类型的数据)
- c. 数据集: Car Evaluation Data Set (关于汽车各类属性的数据, 数值和标称混合的数据)

2. 实验说明

实验通过使用 weka 对数据进行 k-means 聚类, 并对最后的结果进行分析, 实验的步骤如下:

1. 处理数据集
2. 使用 weka 进行聚类
3. 分析实验结果

3. 数据集处理

3.1 数据来源

UCI Repository: <http://archive.ics.uci.edu/ml/datasets.html>

Wine Data Set 包含的内容为: wine.data、wine.names。

Car Evaluation Data Set 包含的内容为: car.data、car.names

3.2 数据集处理

对 Wine Data Set 的 wine.data 进行处理:

1. 将 wine.data 的文件名后缀改为: *.csv。
2. 用 office Excel 打开 wine.csv, 可以得到数据总共有 14 列, 既有 14 个属性。
3. 打开 wine.names, 通过内容可以知道, 其 14 个属性分别为:
 - 1) Class
 - 2) Alcohol
 - 3) Malic acid
 - 4) Ash
 - 5) Alcalinity of ash

- 6) Magnesium
 - 7) Total phenols
 - 8) Flavanoids
 - 9) Nonflavanoid phenols
 - 10) Proanthocyanins
 - 11) Color intensity
 - 12) Hue
 - 13) OD280/OD315 of diluted wines
 - 14) Proline
4. 在 wine.csv 的第一行插入空白行，将上边的属性依次填入其中，如图 2-1 所示：

	A	B	C	D	E	F	G	H	I	J	K	L	M	N
1	Class	Alcohol	Malic aci	Ash	Alcalinit	Magnesium	Total phe	Flavanoic	Nonflavar	Proanthoc	Color int	Hue	OD280/OD3	Proline
2	1	14.23	1.71	2.43	15.6	127	2.8	3.06	0.28	2.29	5.64	1.04	3.92	1065
3	1	13.2	1.78	2.14	11.2	100	2.65	2.76	0.26	1.28	4.38	1.05	3.4	1050
4	1	13.16	2.36	2.67	18.6	101	2.8	3.24	0.3	2.81	5.68	1.03	3.17	1185
5	1	14.37	1.95	2.5	16.8	113	3.85	3.49	0.24	2.18	7.8	0.86	3.45	1480
6	1	13.24	2.59	2.87	21	118	2.8	2.69	0.39	1.82	4.32	1.04	2.93	735
7	1	14.2	1.76	2.45	15.2	112	3.27	3.39	0.34	1.97	6.75	1.05	2.85	1450
8	1	14.39	1.87	2.45	14.6	96	2.5	2.52	0.3	1.98	5.25	1.02	3.58	1290
9	1	14.06	2.15	2.61	17.6	121	2.6	2.51	0.31	1.25	5.05	1.06	3.58	1295

图 3-1

5. 打开 weka 软件，选择 “Tool” → “ArffViewer”，如图 2-2 所示：




图 3-2

6. 在弹出的界面框内，选择 “File” → “Open” 弹出如下图的打开窗口，在文件类型一栏选择 CSV data files (*.csv) 项，如图 2-3 所示；然后找到 wine.csv 文件后单击打开：




图 3-3

7. 接下来选择“File”→“Save as”后弹出如图 2-4 所示，选择 wine.csv 一样的路径，文件类型为 Arff data file(*.arff)，点击保存：




图 3-4

对 Car Evaluation Data Set 的 car.data 进行处理：

处理步骤与上示的 Wine Data Set 中 wine.data 处理方法方法一致，共有 7 个属性，其 7 个属性分别为：

- 1) buying
- 2) maint
- 3) doors
- 4) persons
- 5) lug_boot
- 6) safety
- 7) class

4. SimpleKMeans 实验步骤

对 Wine Data Set 进行 SimpleKMeans 聚类：

1. 打开 weka 软件，进入“Explorer”界面中的“Preprocess”标签，单击 Open file 后弹出如下图的数据集选择窗口，选择 wine.arff 数据集文件后打开。




图 4-1

2. 点击进入“Cluster”：标签，单击左上角“choose”按钮，选择“SimpleKMeans”算法，如下图：




图 4-2

3. 点击“choose”按钮右边显示有“SimpleKMeans....”的框格，将弹出框内“numClusters”栏内的数字改为 3，点击“OK”，如下图：




图 4-3

4. 点击“Ignore attributes”选中“Class”一栏，并点击“Select”确认，默认在聚类时排除该选项。




图 4-4

5. 保持其他选项不变，点击“Start”按钮，开始数据处理，得到数据结果会显示在“Clusterer output”中，如下图。




图 4-5

6. 在实验界面"Result list"列出的结果上右击，点"Visualize cluster assignments".弹出的窗口给出了各实例的散点图。




图 4-6

7. 点击“Save”把聚类结果保存成 arff 文件，命名为：wine result.arff。




图 4-7

对 Car Evaluation Data Set 进行 SimpleKMeans 聚类:

实验步骤与本次 SimpleKMeans 算法的 Wine Data Set 的实验步骤相同，打开的文件为 car.arff，第三步中“numClusters”栏内的数字改为 4，其余步骤完全相同。

6. 实验分析指南

SimpleKMeans 是一种通过数据的距离来对数据集进行分类的算法，其对一些数据型的数据集聚类比较符合其实际分类；而对标称类数据的处理结果可以知道其对标称类数据集聚类会偏离其实际分类结果。可以分析以上 SimpleKMeans 的两个实验结果，验证是否有这些属性。