

迈向高效自动驾驶：深度 Q 学习与能耗优化的结合

第 15 小组. 小组成员: 赵紫楚, 方浩楠, 张明明, 吴小龙

2024 年 5 月 26 日

摘要

随着自动驾驶技术的迅速发展，如何实现更高效、安全的自动驾驶车辆成为研究的热点。本文综合多篇关于自动驾驶的学术论文，探讨了自动驾驶系统中深度 Q 学习的应用、奖励系统设计的优化以及自动驾驶车辆的能耗学习等方向。本文旨在为自动驾驶车辆的发展提供一个多角度、多维度的科学研究视角，为未来自动驾驶技术的发展提供理论支持和实践指导。

关键词: 自动驾驶, 深度 Q 学习, 奖励系统, 能耗学习

Towards Efficient Autonomous Driving: Integration of Deep Q Learning and Energy Consumption Optimization

Group 15. Panelists: Zhao Zichu, Fang Haonan, Zhang Mingming, Wu Xiaolong

2024 年 5 月 26 日

摘要

With the rapid development of autonomous driving technology, how to achieve more efficient and safe autonomous vehicles has become a research hotspot. Based on several academic papers on autonomous driving, this paper discusses the application of deep Q learning in autonomous driving system, optimization of reward system design and energy consumption learning of autonomous driving vehicle. This paper aims to provide a multi-angle and multi-dimensional scientific research perspective for the development of autonomous vehicles, and provide theoretical support and practical guidance for the development of autonomous driving technology in the future.

Keyword:Autonomous driving, deep Q learning, reward systems, energy learning

1 引言

自动驾驶汽车一直是最活跃的研究领域之一 [1] 近年来自动驾驶发展迅速, 同时, 自动驾驶的安全性成了许多人的考虑范围. 而自动驾驶汽车多为新能源电动汽车. 但是即便如此, 许多人对于新能源汽车的自动驾驶抱有许多担忧. 如今, 电动汽车在许多不同的交通系统中发挥着快速增长的作用. 然而, 适用性电动汽车的发展常常受到电池容量有限的限制. 由于历史上的高成本在电池方面, 电动汽车的续航里程通常比传统汽车短得多. 这导致了对电池耗尽时被困的恐惧, 这种效应被称为“里程焦虑”. 这些担忧可能是通过改进这些系统的导航算法和路线规

划方法来缓解这一问题。[2]。同时我们还可以根据强化学习, 强化学习等方式来增加自动驾驶的精准度, 来降低人们对自动驾驶的顾虑

在日本, 政府已经拨出巨额资金, 使自动驾驶技术成为 2020 年奥运会的现实, 因为它被认为是安全高效的交通方式。虽然一辆功能齐全的自动驾驶汽车还有很长的路要走, 但世界上大多数主要的汽车制造商已经达到了开发自动驾驶汽车的高级阶段。然而, 目前的自动驾驶非常昂贵, 因为它往往依赖高度专业化的基础设施和设备, 如用于导航的光探测和测距 (LIDAR)、用于定位的全球定位系统 (GPS) 和用于障碍物检测的激光测距仪 (LRF)[3]

因此如何完善自动驾驶, 降低成本, 增加安全性, 增加效率成为了本文即将讨论的重点。本文将探讨自动驾驶汽车的当前技术和挑战, 尤其是在学习算法、奖励系统设计以及能效管理方面的最新进展, 以期对未来自动驾驶汽车的安全、可靠和经济高效运行提供见解和解决方案。

1.1 相关工作

自动驾驶汽车的研究已经有很多年了, 而且在不同的国家都有不同的研究方向。深度 Q 网络 (Deep Q Network, DQN) 是强化学习的一种形式。我们可以使用 DQN 来训练自动驾驶汽车, 使其能够在不同的环境下做出正确的决策。其中, CNN 的输出不是分类, 而是对输入产生的动作给予的 Q 值 (奖励)。DQN 代理直接学习成功的策略从高维感官输入使用端到端强化学习。最近, DQN 在经典 Atari 2600 游戏的挑战领域取得了成功 [4]。人类驾驶的大量标记数据是训练任何自主派生系统所必需的。DQN 学习使代理能够从自己的行为中学习, 而不是从标记的数据中学习。经过几个小时的训练, 它学习在车道之间平稳驾驶, 并仅通过视觉信息输入来避开障碍物。[5]

2 研究现状

2.1 Q 学习对于自动驾驶路线规划的应用

2.1.1 强化学习的主要框架

强化学习 (Reinforcement Learning, RL) 是一种机器学习范式, 旨在通过与环境的交互来学习如何采取行动, 以最大化累计奖励。不同于监督学习, 强化学习不需要标注的输入输出对, 而是通过试错来学习最佳策略。强化学习的核心组件包括:

1. 智能体 (Agent): 在环境中采取行动的实体。
2. 环境 (Environment): 智能体与之交互的外部系统。
3. 状态 (State): 环境在某一时刻的具体情况。
4. 动作 (Action): 智能体在某一状态下可以采取的行为。
5. 奖励 (Reward): 智能体采取某一动作后环境给予的反馈信号。
6. 策略 (Policy): 智能体从状态到动作的映射规则。
7. 价值函数 (Value Function): 评估每个状态或状态-动作对的长期收益。

强化学习的主要框架如图 1所示。目前, 强化学习中最具有代表性的算法是 Q-learning 算法 [6], 该算法能在与环境的互动过程中学习环境各状态的 Q 值, 根据 Q 值得出最优策略。而 DQN 算法则是利用卷积神经网络来提取特征从而指导智能体的决策过程的一种算法。本文中我们将主要分析强化学习中的 Q-learning 以及基于 Q-learning 的 DQN(Deep Q Network) 算法

2.1.2 深度 Q 学习的原理

Deep Q-Learning (深度 Q 学习) 是一种用于强化学习的算法, 同时也是强化学习中一个非常具有代表性的算法。它结合了深度学习和 Q 学习的优点, 能够在复杂的环境中做出决策。强化学习是一种机器学习方法, 它通过与环境的互动来学习如何做决策。算法会尝试不同的动作, 根据获得的奖励 (或惩罚) 来调整策略, 目的是最大化总奖励。

我们还可以使用 Q 学习来进行能耗的优化。DQN 是一种将深度学习与强化学习结合的算法, 其核心在于利用卷积神经网络 (CNN) 从高维感官输入中提取特征, 并通过 Q 值函数指导智能体的决策过程。DQN 通过经验回放和固定 Q 目标网络解决了传统 Q 学习中的不稳定问题。经验回放缓解了数据相关性问题, 而固定 Q 目标网络则减轻了训练过程中值函数的振荡。实验表明, DQN 在复杂环境下表现出色, 能够有效学习并优化自动驾驶策略。Q 学习是强化学习的一种变体。在 Q 学习中, 存在一个具有状态和相应动作的智能体。在任意时刻, 智能体处于某一可行状态。在下一个时间步, 通过执行某个动作, 状态转变为其他状态。这个动作伴随着奖励或惩罚。智能体的目标是最大化奖励的获取。Q 学习算法通过以下更新公式表示:

$$Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$$




图 1: 强化学习的框架图

其中, $Q(s_t, a_t)$ 表示在时间 t 时, 智能体处于状态 s_t 并执行动作 a_t 的 Q 值, 奖励为 r_t 。 α 是学习率, γ 是折扣因子。参数 γ 的取值范围是 $[0,1]$ 。如果 γ 接近 0, 智能体将倾向于只考虑即时奖励。相反, 如果 γ 接近 1, 智能体将更重视未来的奖励, 从而愿意延迟奖励。学习率和折扣因子是影响 Q 学习算法性能的两个最重要的参数。DQN 算法的伪代码则如算法 1所示

2.1.3 学习率

学习率决定了新获取的信息覆盖旧信息的强度。学习率为 0 时, 智能体不会学习任何东西, 而学习率为 1 时, 智能体只会考虑最新的信息。在完全确定性的环境中, 学习率为 1 是最优的。当问题是随机的时, 算法在某些技术条件下仍能收敛, 这些条件要求学习率逐渐减小到零。在实践中, 通常使用恒定的学习率。

2.1.4 折扣因子

折扣因子决定了未来奖励的重要性。折扣因子为 0 时, 智能体将变得短视, 只考虑当前的奖励; 而折扣因子接近 1 时, 智能体将努力追求长期的高奖励。如果折扣因子等于或超过 1,

Algorithm 1 深度 Q 学习算法

Require: 初始参数 θ_0

```
1: 初始化容量为  $N$  的经验回放记忆库  $D$ 
2: 随机初始化神经网络  $Q$  的参数  $\theta$ 
3: 初始化目标网络  $\hat{Q}$  的参数  $\theta' = \theta$ 
4: for episode = 1 to  $M$  do
5:   初始化状态  $s_1 = \{x_1\}$ , 预处理得到神经网络的输入特征  $\phi(s_1)$ 
6:   for  $t = 1$  to  $T$  do
7:     以  $\epsilon$  的概率随机选择一个动作  $a$ 
8:     否则  $a = \arg \max_{a'} Q(\phi(s_t), a'; \theta)$ 
9:     执行动作  $a$ , 获得奖励  $r$  并且模拟器返回下一个时刻的一帧图像  $x_{t+1}$ 
10:     $s_{t+1} = s_t, a_t, x_{t+1}$ , 预处理得到  $\phi_{t+1} = \phi(s_{t+1})$ 
11:    将  $(\phi_t, a_t, r, \phi_{t+1})$  存储到  $D$  中 (如果  $D$  满了那么会弹出老的)
12:    随机从  $D$  中采样一个小批量的数据  $(\phi_j, a_j, r_j, \phi_{j+1})$ 
13:    if  $t + 1$  时刻是游戏结束 then
14:       $y_j = r_j$ 
15:    else
16:       $y_j = r_j + \gamma \max_{a'} \hat{Q}(\phi_{j+1}, a'; \theta')$ 
17:    end if
18:    使用梯度下降优化损失函数  $(y_j - Q(\phi_j, a_j; \theta))^2$ 
19:    if 每过  $C$  次训练 then
20:      更新一次目标网络的参数  $\theta' \leftarrow \theta$ 
21:    end if
22:  end for
23: end for
```

动作值可能会发散。即使折扣因子仅略低于 1, 当使用人工神经网络来近似值函数时, Q 学习也会导致误差传播和不稳定性。在这种情况下, 已知从较低的折扣因子开始, 并逐渐增加到最终值, 可以加速学习。

2.2 卷积神经网络对于深度 Q 学习的作用

一般来说,神经网络模仿生物神经元的功能,其激励信号可以根据输入刺激的强度打开/关闭。包含组合矩阵运算和非线性激活函数的多层前馈神经网络在解决分类问题上有很好的效果。例如,MINST 数据集中 0-9 位数图像的分类误差低至 3%。然而,在 CIFAR-10 数据集的分类中,有十类图像,如狗,鸟等,测试误差增加到 50% 左右。mlp 在图像分类方面的糟糕表现引发了一种新的神经网络,称为卷积神经网络 (CNN)。卷积神经网络 (Convolutional Neural Network, CNN) 是一种正则化的前馈神经网络,通过滤波器 (或称核) 优化自行学习特征工程。通过使用正则化的权重和较少的连接数, CNN 可以避免早期神经网络在反向传播过程中遇到的梯度消失和梯度爆炸问题。

在传统的全连接层中,每个神经元处理一个 100×100 像素的图像需要 10,000 个权重。然而,使用级联的卷积 (或交叉相关) 核,仅需要 25 个神经元处理 5×5 大小的图块。高层特征是从更宽的上下文窗口中提取的,而低层特征则从较小的上下文窗口中提取。这使得 CNN 能够更有效地处理图像,并逐层提取越来越复杂的特征。

总结来说, CNN 通过优化卷积核,自动学习图像特征,并通过逐层处理来提取不同层次的特征,从而在图像识别等任务中表现出色。

2.3 CNN 与 DQN 的联系

Deep Q Network (图 2) 是 CNN(图 3) 的一个变体。输出不是类,而是对应于代理在环境中学习的响应其状态的每个动作的 Q 值。卷积神经网络 (Convolutional Neural Network, CNN) 和深度 Q 网络 (Deep Q Network, DQN) 在结构和功能上有很多联系,但也有显著的不同之处。以下是对它们联系的分析:

- 基础结构:
 - CNN: CNN 的基础结构包括卷积层、池化层和全连接层。这些层通过提取图像特征,最终将输入图像分类到特定的标签类别中。
 - DQN: DQN 的基础结构中也包含 CNN,用于处理和提取输入状态 (通常是图像) 的特征。这些特征随后被传递到全连接层,以估计 Q 值。
- 特征提取:




图 2: DQN 框架

- 在 CNN 中，卷积层和池化层用于提取输入图像的特征。这些特征用于分类任务。
- 在 DQN 中，卷积层和池化层同样用于提取输入状态（图像或其他形式）的特征。这些特征用于估计每个可能动作的 Q 值。

• 学习过程:

- CNN 通过反向传播和梯度下降算法来优化模型参数，使得模型能够在给定的训练数据上进行分类。
- DQN 通过 Q-learning 算法来更新 Q 值，结合反向传播和梯度下降算法，优化模型参数，使得模型能够在不同的环境状态下选择最优动作。

但是同时, 两者也是有着一些不同点:

• 输出类型:

- CNN: 输出的是类别标签，即模型将输入图像分类为特定类别的概率。




图 3: CNN 框架

- **DQN**: 输出的是每个动作的 Q 值，即在当前状态下采取每个可能动作的预期奖励。
- 应用场景:
 - **CNN**: 主要用于图像分类、目标检测、图像分割等静态图像处理任务。
 - **DQN**: 主要用于强化学习任务，即在动态环境中通过与环境的交互来学习最优策略，例如游戏 AI、机器人导航等。

- 目标函数:

- CNN: 使用交叉熵损失函数或其他分类损失函数, 最小化分类错误率。
- DQN: 使用贝尔曼方程更新 Q 值, 目标是最小化 Q 值的时间差误差。

总结来说, CNN 和 DQN 在特征提取部分有很大的相似性, 都是通过卷积神经网络来处理和提取输入特征。但它们的最终目的和输出类型有所不同, CNN 用于静态图像的分类, 而 DQN 用于动态环境中的决策优化。

3 深度 Q 学习在车辆自动驾驶方面的实验结果

3.1 实验环境

图像 4 和图像 5 展示了模拟研究中创建的学习环境。在两侧由人行道界定的直路上, 每隔 30 米随机放置障碍物。这些障碍物包括以下三种类型:

- 人形 (图 6)
- 车辆 (图 7)
- 障碍块 (图 8)

这些静态障碍物是从预先制作的集合中随机生成的。模拟环境是使用 Unity (<https://unity3d.com/>) 创建的。Unity 与 Python 程序之间的交互是通过 Unity-Python 转换模块 (<http://ailab.dwango.co.jp/en/>) 实现的。学习过程是使用 Chainer 框架 (<http://chainer.org/>) 实现的。本篇文章 [5] 的实验环境如下:

- CPU: 8 核 Xeon CPU x 2
- 内存: 256 GB RAM
- 显卡: Nvidia P100 GPU x 5

3.2 代理动作

DQN 从摄像头输入中解释汽车前方的道路场景, 并为给定的时间段提出具体的行动计划。为了简化行动计划, 我们只考虑三种动作: 向左转 10 度、保持直行、向右转 10 度 (图 9)。




图 4: 生成障碍物

3.3 实验内容

实验会一直重复状态-动作循环, 直到智能体到达目标. 在本次实验中, 智能体即为小车. 如果在状态-动作循环中, 智能体碰到障碍物或越过边界车道, 学习回合将中止, 智能体将开始一个新的回合. 如果智能体在轨道上顺利行进, 它会在每克服一个障碍物时得到奖励. 智能体更新轨迹信息的频率是 0.15s 一次. 在智能体更新了轨迹信息后, 智能体会将轨迹信息发送给学习程序. 学习程序在分析了智能体的轨迹信息后, 会发送适当的行为给智能体. 智能体收到了学




图 5: 障碍物在街道上的位置

习程序发送的信息后, 将会根据学习程序的指示来进行适当的行动. 实验分别在 10m/s , 15m/s 以及 20m/s 的速度下进行. 小车将会在这样的恒定速度下行驶, 在小车行驶时, 我们将会记录下小车的轨迹以及小车的运动情况




图 6: 人形组件



图 7: 车辆组件



图 8: 障碍物组件

3.4 学习结果

在文章中, 小车进行了多次测试. 每种速度下的最高得分如图 10所示, 学习智能体在每种速度下避开所有车道和障碍物的最长距离如表格 1所示。在小车的速度为 10m/s 时, 小车的行



图 9: 行动计划

驶距离是最远的, 达到了 10077m. 这也符合我们的预期. 在小车的速度比较缓慢时, 学习程序将会有更多的时间来分析小车的运动并且给出最优的行驶路线, 这也导致了小车的行驶距离会比较长. 因此我们可以得出这样的结论: 智能体的学习能力随着驾驶速度的增加而下降。

实验	车速 (米/秒)	行驶距离 (米)
1	10	10,077
2	20	4,907
3	30	2,173

表 1: 成功学习




图 10: 三种不同速度的平均得分

4 未来展望

在未来的研究中, 我们可以进一步研究如何将深度 Q 学习应用到自动驾驶汽车中, 以提高自动驾驶汽车的性能. 随着自动驾驶技术的发展, 未来的研究可以从以下几个方向进行深入:

4.1 算法与模型的融合与创新

尽管深度 Q 学习在决策过程中已显示出其有效性，我们预计通过与其他机器学习技术如卷积神经网络（CNN）或递归神经网络（RNN）的结合，可以进一步优化决策过程。例如，使用 CNN 处理视觉输入以识别路况和障碍物，而 RNN 可以用来处理时间序列数据，以预测交通流量和车辆动态。

4.2 能效优化的深层研究

当前研究已涉及到如何通过算法优化能源消耗，未来可以在此基础上，探索更多维度的能源管理策略，如考虑不同气候条件和路面状况下的能源效率，以及如何在车队管理中实施这些策略。

4.3 实验与实际应用

理论研究和算法开发后，进行实地测试至关重要。建议设计一系列基于模拟环境的实验，进而在封闭道路或指定测试区域进行现实世界的试验，以验证算法在实际驾驶场景中的表现和可靠性。

4.4 跨领域的应用研究

探索深度 Q 学习在自动驾驶以外领域的应用，例如无人物流、自动化仓储系统等，这些领域对自动化和精确控制的需求日益增加。

4.5 伦理与法律研究

自动驾驶技术的推广不仅是技术问题，还涉及伦理和法律问题。当前有关自动驾驶汽车伦理困境的讨论主要与道德哲学中著名的“电车难题”相关。“电车难题”是由哲学家 Philippa Foot 于 1967 年提出的著名思想实验，用以批判功利主义，其基本设定是：你可以通过变轨使一辆失控的电车撞向一个人或者不变轨使电车撞向 5 个人。在后来的几十年时间里，道德哲学家发展出了大量变体。而如果一辆自动驾驶汽车也面临类似不可避免的交通事故，AI 系统会选择撞向谁？应该牺牲车内乘客还是路上行人？2015 年 Mitchell Waldrop 在《自然》发表的报告显示：如果事故不可避免，多数人不愿将选择权交由机器。如果没有明确的伦理规则出台以指

导无人驾驶汽车的事故决策，将很难改变用户目前的不信任状态，甚至可能导致人们拒绝购买自动驾驶汽车。[7] 因此，界定自动驾驶汽车伦理规范已经迫在眉睫，但当前的理论研究尚处于起步阶段。[8] 研究如何制定合理的政策和法规，确保自动驾驶技术的发展既符合道德标准，又符合法律规定，尤其是在处理可能的事故和责任归属时。

通过上述方向的探索，未来的研究将有望在提高自动驾驶汽车的性能、安全性和能效方面取得重要进展。同时，这些研究将有助于自动驾驶技术的广泛应用，推动相关行业的进一步发展。

5 写作心得

本文主要讨论了自动驾驶汽车的能效提升问题，并且从多个角度进行了分析，包括深度 Q 学习，奖励系统设计，能耗学习等方面。在撰写这篇关于自动驾驶汽车能效提升的论文的过程中，我遇到了许多挑战和收获。首先，我需要收集研究资料，因为自动驾驶是一个跨学科的领域，涉及到机器学习、能源管理和电子工程等多个领域。通过仔细阅读多篇学术论文和技术报告，我了解到自动驾驶的技术框架和关键问题。

接下来，深度 Q 学习模型的应用是本文的核心之一。为了解释深度 Q 学习如何优化自动驾驶系统的决策过程，我不仅需要了解相关技术细节，还需要能够简明扼要地解释这些复杂的概念。通过资料的查阅，我逐渐改进了论文的表述方式，使其更加清晰易懂。

最后，关于写作风格和结构的安排，我努力使文章的结构清晰且逻辑严密。通过多次修改，我了解到如何更有效地组织学术论文，使每个部分都紧密联系在一起，逻辑流畅。

参考文献

- [1] Brian Paden, Michal Čáp, Sze Zheng Yong, Dmitry Yershov, and Emilio Frazzoli. A survey of motion planning and control techniques for self-driving urban vehicles. *IEEE Transactions on Intelligent Vehicles*, 1(1):33–55, 2016.
- [2] Niklas Åkerblom, Yuxin Chen, and Morteza Haghiri Chehreghani. Online learning of energy consumption for navigation of electric vehicles. *Artificial Intelligence*, 317:103879, 2023.

- [3] Mohamed Aly. Real time detection of lane markers in urban streets. *2008 IEEE Intelligent Vehicles Symposium*, pages 7–12, 2008.
- [4] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A Rusu, Joel Veness, Marc G Bellemare, Alex Graves, Martin Riedmiller, Andreas K Fidjeland, Georg Ostrovski, et al. Human-level control through deep reinforcement learning. *nature*, 518(7540):529–533, 2015.
- [5] Takafumi Okuyama, Tad Gonsalves, and Jaychand Upadhay. Autonomous driving system based on deep q learnig. In *2018 International Conference on Intelligent Autonomous Systems (ICoIAS)*, pages 201–205, 2018.
- [6] Christopher J. C. H. Watkins and Peter Dayan. Q-learning. *Machine Learning*, 8(3):279–292, 1992.
- [7] M Mitchell Waldrop et al. No drivers required. *Nature*, 518(7537):20, 2015.
- [8] 白惠仁. 自动驾驶汽车的伦理, 法律与社会问题研究述评. *科学与社会*, 8(1):72–87, 2018.